

**Análisis de Expresión Diferencial del Transcriptoma durante la Transición de
Pluripotencia a Endodermo Definitivo en Células Madre Humanas: Una
Reproducción Computacional del Experimento E-MTAB-9194**

Laura del Sol González

Universidad EIA

Trabajo Final Bioinformática

2025

Descripción del estudio original

El estudio "Epigenetic and transcriptional regulations prime cell fate before division during human pluripotent stem cell differentiation" investiga los cambios dinámicos en el transcriptoma y el epigenoma durante la diferenciación de células madre embrionarias humanas (hESC) hacia endodermo definitivo (Madrigal et al., 2023). Para ello, los autores establecieron un sistema de diferenciación sincronizada utilizando el reportero FUCCI (Fluorescent Ubiquitination-based Cell Cycle Indicator), que permite visualizar y aislar poblaciones celulares en fases específicas del ciclo celular en base a la fluorescencia de proteínas ligadas a ubiquitina. Gracias a este sistema, los autores pudieron sincronizar las células en la fase G1 temprana (0 horas), estableciendo un punto de partida homogéneo y bien definido para inducir la diferenciación de manera coordinada.

En el diseño experimental, las células en la fase G1 temprana representan el estado de pluripotencia de las hESC no diferenciadas. Por el contrario, el tiempo de 72 horas representa una etapa avanzada en la que las células han activado los programas transcripcionales de diferenciación y se han diferenciado al linaje de endodermo definitivo, como lo demuestra la expresión de marcadores específicos clave (Madrigal et al., 2023). Esta ventana de tiempo es una transición celular fundamental, que es la pérdida del estado pluripotente y la adquisición de una nueva identidad celular especializada (Madrigal et al., 2023). En el estudio original se realizó un análisis de la expresión génica diferencial a lo largo de una serie temporal completa que comprendía de las 0 a las 72 horas pasando por intervalos de tiempo de 12, 24, 36, 48 y 60 horas para determinar mecanismos dependientes del ciclo celular en los diferentes periodos de tiempo donde la célula entraba en 2 fases del ciclo celular. Sin embargo, este proyecto se centra en el contraste más fundamental entre el estado inicial y el estado final diferenciado, pues el replicar las condiciones que se planteaban en el estudio para ver en qué fase del ciclo se encontraba la célula ya no era parte del análisis diferencial, además que se desarrollaban en tiempos distintos a las 72 horas. A pesar de esto la comparación directa entre estos dos estados es biológicamente muy importante y adecuada para un análisis de expresión diferencial menos completo. Se espera que esta transición esté impulsada por amplios cambios transcriptómicos, incluida la supresión de genes asociados con la pluripotencia y la activación de una red génica que impulsa la especificación del endodermo.

Diseño experimental

El diseño experimental del estudio original comprendió una serie temporal con siete puntos de muestreo (0, 12, 24, 36, 48, 60 y 72 horas) para capturar la dinámica de la diferenciación. Para el presente análisis, se definió un contraste específico entre dos condiciones biológicas discretas: células madre embrionarias humanas (hESC) en estado de pluripotencia (0 h) versus células diferenciadas a endodermo definitivo (72 h).

La variable biológica central es el estado de diferenciación celular, representado por dos niveles: el estado inicial pluripotente (0 h) que actúa como control, y el estado final de endodermo definitivo (72 h) que constituye el tratamiento o condición experimental.

Cada condición cuenta con tres réplicas biológicas independientes. Estas réplicas consisten en cultivos celulares preparados de forma separada y sometidos al protocolo de diferenciación de manera independiente, lo que permite capturar la variabilidad biológica inherente al proceso y garantiza la robustez estadística del análisis.

Análisis metodológico

Primero se extrajeron conteos crudos y metadatos desde Expression Atlas, seleccionando sólo las muestras de interés (réplicas 0 h y 72 h) como se muestra en el README. Se formó una matriz de conteos con genes como filas y muestras como columnas, y se creó el objeto DESeq2 con diseño de tiempo como factor. Se filtraron genes de muy baja expresión (suma de conteos ≤ 10) antes del análisis para reducir ruido.

Tras ejecutar DESeq2 (estimación de tamaños de librería, dispersión y test de Wald) se obtuvieron valores de $\log_2FC$ y p-valores ajustados. Como umbrales de significancia se usaron $FDR (padj) < 0.01$ y $\log_2FC \geq \log_2(1.5)$ siguiendo el criterio del estudio original. El uso de FDR controla la tasa de falsos positivos en pruebas. Se identificaron aproximadamente 9600 genes diferencialmente expresados bajo estos criterios. Entre los más significativos destacan los marcadores de diferenciación upregulated (EOMES, SOX17, GATA4, LZTS1) y los marcadores de diferenciación down regulated (DAZL, SOX2, HES3 y POI5F1). El primer grupo se analizó ya que se mencionaban estos genes en el artículo, mientras que del segundo grupo los genes DAZL y HES3 fueron seleccionados al presentar los valores más extremos de down-regulación en el análisis diferencial. HES3 destacó por su silenciamiento prácticamente completo con un $\log_2FC$ de -29.97 y un p-valor ajustado muy bajo ($5.31e-182$), indicando una pérdida total de expresión durante la diferenciación.

Durante el análisis se realizaron controles de calidad: se aplicó la transformación VST para homogeneizar varianza y se generó un PCA para verificar la separación nítida entre condiciones. También se calculó la matriz de correlación de Spearman entre réplicas, mostrando alta concordancia y clustering adecuado, esto también se hizo siguiendo el criterio del estudio original.

Resultados




Figura 1. Boxplots de genes marcadores upregulated. Muestra los conteos brutos de EOMES, SOX17, LZTS1, GATA4 en 0 h vs 72 h. Se observa que en el tiempo 0 los niveles son bajos/ausentes y en el tiempo 72 los niveles aumentan drásticamente, consistente con la activación de la ruta endodérmica.




Figura 2. Boxplots de genes marcadores downregulated. Muestra los conteos brutos de DAZL, SOX2, HES3 y POU5F1 en 0 h vs 72 h. Se observa que en el tiempo 0 los niveles son muy altos y en el tiempo 72 los niveles disminuyen drásticamente, consistente con la diferenciación de las células hESC a células endodérmicas.




Figura 2. MA-plot. El MA-plot relaciona la expresión media de cada gen con su log₂FC. Se aprecia una nube dispersa alrededor de cero, con los genes significativamente diferenciados resaltados. La simetría sugiere un balance entre genes sobre- y sub-expresados, y muestra que los cambios más extremos corresponden a genes de baja o media expresión. Este gráfico permite detectar sesgos (que no hay) y confirma la proporción de genes con grandes cambios.




Figura 3. PCA: Separación entre 0h y 72. El diagrama de componentes principales muestra dos grupos bien diferenciados por tiempo (0 h en rojo, 72 h en azul). El primer componente (PC1) captura casi toda la variación biológica entre estados celulares (el código nos dice que PC1 representa el 100% de la varianza mientras que el PC2 representa el 0%), indicando que el cambio celular es la fuente principal de variabilidad. Esto refuerza la calidad del proyecto y la consistencia de los replicados diferenciados.




Figura 4. Heatmap de correlación. El mapa de calor de la correlación de Spearman entre muestras (sólo genes altamente expresados) revela correlaciones elevadas (≥ 0.92) entre réplicas del mismo tiempo y diferencia entre muestras de otros tiempos. El clustering jerárquico agrupa correctamente los tres réplicas de 0 h por un lado y de 72 h por otro, confirmando la alta correlación interna.




Figura 5. Volcano plot. El volcán representa cada gen según $\log_2 FC$ y $-\log_{10}(padj)$. Los genes con mayor significancia (puntos en la cima) son también los de mayor cambio. Los cortes umbrales ($FC \geq 1.5$, $padj < 0.01$) definen zonas evidentes de genes significativos. Por ejemplo, se visualizan claramente los marcadores endodérmicos en el lado positivo (hasta $\log_2 FC = 5$) y los pluripotentes en el negativo. Así, el volcán ayuda a seleccionar genes relevantes.

La diferenciación de hESC a endodermo definitivo implica una reprogramación transcripcional donde el programa de pluripotencia (caracterizado por OCT4/POU5F1, SOX2 y NANOG) es reemplazado por un programa especializado para formar órganos internos como hígado y páncreas. Esta transición es inducida por las vías que activan factores endodérmicos como SOX17 y FOXA2 mientras reprimen los factores de pluripotencia (D'Amour et al., 2005). Los datos confirman este patrón, mostrando un

aumento significativo de SOX17 y FOXA2 junto con una disminución marcada de POU5F1 y SOX2 tras 72 horas de diferenciación, validando la transición al linaje endodérmico.

Entre los genes diferenciales clave, destacan:

- **EOMES (Eomesodermina):** es un factor temprano de endodermogénesis. Marca el inicio del engrosamiento endodérmico y colabora con SMAD2/3 para activar la red genética endodérmica (Diekmann, U et al. , 2019). Su pérdida impide la expresión de SOX17, FOXA2, GATA4. Su expresión se induce tras los 24–36 h de diferenciación. En el análisis realizado aparece altamente sobreexpresado en 72 h.
- **SOX17 y GATA4:** ambos son factores de transcripción importantes del endodermo definitivo. SOX17 regula genes de endodermo y sirve para la formación de los órganos como intestino y páncreas (Diekmann, U et al. , 2019). GATA4 (junto con GATA6) activa genes endodérmicos tempranos; su inducción coopera con EOMES/SMAD2/3 para consolidar la identidad endodérmica (Diekmann, U et al. , 2019). La fuerte inducción observada de SOX17 y GATA4 en 72 h refleja esta función.
- **LZTS1 (leucine zipper, putative tumor suppressor 1):** Aunque originalmente fue asociado a regulación de ciclo celular, estudios recientes (Madrigal et al., 2023) identifican a LZTS1 como regulador potencial del endodermo. Su expresión aumenta rápidamente después de 36 horas. También se observó que la sobreexpresión de LZTS1 en hESCs potencia la expresión de otros genes (Diekmann, U et al. , 2019). El hallazgo de LZTS1 en los resultado dio que estaba medianamente inducido ($\log_2FC=4.68$) .
- **SOX2 y POU5F1 (Oct4):** Ambos son factores de transcripción centrales en el núcleo de pluripotencia de las células madre. SOX2, en conjunto con POU5F1 y NANOG, forma el circuito central de autorregulación que mantiene el estado no diferenciado, suprime la diferenciación espontánea y controla la expresión de genes diana. La expresión de estos factores es máxima en las células madre pluripotentes y debe ser reprimida para que ocurra cualquier proceso de diferenciación. La fuerte supresión observada de SOX2 y POU5F1 a las 72 horas es un indicador claro de la salida del estado pluripotente.
- **HES3 (Hairy and enhancer of split-3):** Actúa como un represor transcripcional. HES3 está típicamente asociado con el mantenimiento de poblaciones progenitoras neurales y la inhibición de la diferenciación neuronal prematura. Su expresión en células madre pluripotentes humanas (hPSCs) se asocia con un estado de reposo, y su downregulation es consistente con la activación de programas de diferenciación.

En conjunto, el panorama transcriptómico global revela un cambio masivo, pues miles de genes alteran su expresión, reflejando la migración de redes de pluripotencia a redes de destino celular. Estudios confirman que la mayoría de la variación ocurre durante la fase G1 temprana y antes/después de las primeras divisiones celulares en este sistema, lo cual es coherente con nuestra observación de variabilidad concentrada en la diferenciación inicial. La lista de genes diferenciados por el estudio se sabe que incluyen funciones metabólicas, de señalización celular y cambio en la cromatina mostrando la complejidad del proceso tal como lo documentan Madrigal et al. (2023). Lo que significa que la evidencia que el cambio de estado está dirigido por la transcripción de factores específicos (EOMES, SOX17, GATA4, LZTS1) y por la represión de la red pluripotente.

Comparación con Expression Atlas

Este análisis reproduce las tendencias reportadas por Expression Atlas. En particular, **EOMES, SOX17, GATA4 y LZTS1** aparecen sobre expresados en 72 h vs 0 h y concuerda en dirección (todos hacia arriba) y magnitud creciente (variaciones de varios órdenes de magnitud). Por ejemplo, el incremento $\log_2FC$ de EOMES (5.79) y SOX17 (5.46) en los datos es consistente con la marcada inducción en endodermo de estos genes. Además, el número total de genes diferenciados que se encontraron (aproximadamente 9600 con los filtros propuestos) es aproximadamente el mismo orden de magnitud que el reportado en Expresión atlas (aproximadamente 7000), las diferencias numéricas pueden explicarse por usar umbrales distintos o filtrados previos de conteos no explicados en el artículo, y por métodos de normalización diferentes. A pesar de esto, la superposición de genes relevantes es alta.

En cuanto a validación cruzada, se encontró que los hallazgos biológicamente importantes como la activación de LZTS1 y de los marcadores endodérmicos aparecen de forma reproducible. Por ejemplo, ambos conjuntos de datos señalan que LZTS1 surge como regulador ligado al endodermo. Finalmente, al ver los patrones de expresión se encuentran que más o menos la mitad son ascendentes y el resto descendentes, algo que también se ve en el expresión atlas.





Imagen 1. Comparación de los genes Downregulated only y Upregulated only de expresión atlas para 0 vs 72 horas.

Gene ID	chromosome_name	start_position	end_position	baseMean	log2FoldChange	lfcSE	stat		pvalue	padj	Gene Name
ENSG000001chr11	3339261	3379222	91.152.153.643.713	-0.58779283	0.036462847	-161.203.217.266.414	1.84E-45	1.43E-43	ZNF195		
ENSG000001chrX	48903180	48911958	358.525.411.261.624	-0.587445031	0.042272868	-138.965.029.710.114	6.65E-30	4.30E-29	SC35A2		
ENSG000001chrX	16567950	16712976	69.617.551.518.714	-0.587321512	0.029994385	-195.810.487.547.834	2.24E-72	2.35E-70	CTPS2		
ENSG000001chr5	129459686	129738683	238.047.909.831.729	-0.587056353	0.049933477	-117.567.683.431.023	6.52E-18	3.42E-17	ADAMTS19		
ENSG000001chr16	84699971	84779926	154.719.208.592.382	-0.586916708	0.02728245	-215.126.098.415.524	1.19E-88	1.47E-87	USP10		
ENSG000001chrX	49187807	49202218	221.004.632.664.199	-0.586768447	0.130482457	-420.675.589.367.731	2.39E+09	6.09E+09	SIP		
ENSG000001chr4	35287456	35366399	907.969.278.628.612	-0.586594218	0.029614024	-198.079.875.711.159	2.54E-74	2.72E-72	RFC1		
ENSG000001chr10	24848614	24952606	102.999.866.557.638	-0.58653375	0.072362885	-810.550.182.231.511	5.25E-02	1.94E-01	PRTFDC1		
ENSG000001chr21	43659560	43696079	118.753.252.212.692	-0.586465606	0.027842063	-210.640.140.368.268	1.70E-84	2.04E-83	RRP18		
ENSG000001chr11	10308162	10507877	349.712.196.306.525	-0.586442963	0.108354487	-541.226.285.009.188	6.22E+06	1.71E+07	AMPD3		
ENSG000001chrX	135520622	135582534	174.152.200.584.735	-0.586421057	0.053689359	-109.224.819.309.679	9.00E-14	4.36E-15	INTS6L		
ENSG000001chr13	52842889	52848641	339.720.629.131.275	-0.586183766	0.120599974	-486.872.002.327.151	1.12E+08	2.88E+08	PCDH8		
ENSG000001chr12	6967119	6870498	507.219.651.997.735	-0.586074573	0.020125754	-291.206.275.834.889	1.97E-172	4.16E-171	TPH1		
ENSG000001chr12	122471600	122500932	383.534.795.789.538	-0.585967872	0.038638352	-151.579.178.320.747	6.72E-38	4.81E-38	ZCCHC8		
ENSG000001chr12	113056710	113098028	552.762.713.120.933	-0.585570897	0.087160825	-671.828.080.863.186	1.84E+03	5.88E+03	DTX1		
ENSG000001chr22	17178790	17258235	711.319.270.002.383	-0.585510101	0.032837073	-178.307.642.576.371	4.08E-57	3.73E-56	ADA2		
ENSG000001chr2	68679601	68626833	412.119.081.040.559	0.585183882	0.104748006	558.651.039.311.931	2.32E+06	6.50E+06	ARHGAP25		
ENSG000001chr20	7877346	8013613	392.773.253.156.346	0.58537754	0.047413241	123.462.882.448.323	5.10E-21	2.84E-20	THK4		
ENSG000001chr1	9848269	9910368	471.568.327.232.792	0.585398854	0.033938342	172.488.938.682.745	1.14E-52	9.95E-52	CTNBP1		
ENSG000001chr8	89545423	89902429	136.048.301.543.914	0.585972074	0.060874487	962.590.422.899.823	6.22E-08	2.66E-07			
ENSG000001chr17	32040437	32041524	196.495.836.779.138	0.58630029	0.143494692	408.586.744.493.689	4.39E+08	0.000102	SHGOLIP1		
ENSG000001chr4	185204237	185390928	266.212.525.406.165	0.586351621	0.045887956	127.778.980.527.813	2.18E-23	1.27E-22	SNX25		
ENSG000001chr15	89608789	89663098	266.289.342.880.796	0.586409879	0.042010556	139.600.598.944.222	2.73E-30	1.77E-29	KIF7		
ENSG000001chr2	232857279	232878768	107.533.931.269.165	0.586811783	0.133989276	392.487.022.485.002	0.002487	0.004901	SNORC		
ENSG000001chr12	10589386	10598209	323.056.671.255.346	0.586977544	0.112913716	51.984.609.643.249	2.01E-06	5.38E-07	KLRP1		
ENSG000001chr6	8435542	9294133	100.463.012.796.777	0.588537399	0.207353852	283.832.391.921.088	0.004535	0.008662	HULC		
ENSG000001chr8	19711111	1974803	112.361.632.571.655	0.588697038	0.195159383	301.649.363.557.921	0.002557	0.005034			
ENSG000001chr17	81017969	81034881	256.854.446.077.302	0.588853235	0.044474647	13.240.200.234.802	5.14E-26	3.13E-25	BAIAP2-DT		
ENSG000001chr19	57191500	57222846	215.586.064.121.296	0.589301013	0.050153952	117.498.421.020.409	7.08E-18	3.71E-17	ZNF264		

Imagen 2. En el archivo `deseq_filtrado_FC1.5_padj.csv` se organizó el `logfoldchange` de menor a mayor y en el dato 5004 se observa el cambio de down a up regulated.

Conclusión

Este proyecto demuestra la viabilidad de reproducir un análisis de expresión diferencial de RNA-seq a partir de datos públicos, validando los hallazgos centrales del estudio original de Madrigal et al. (2023). El análisis confirmó el patrón transcripcional característico de la diferenciación a endodermo definitivo, con la represión de genes de pluripotencia y la activación significativa de reguladores endodérmicos clave. Los controles de calidad realizados, incluyendo el PCA que mostró una separación del 100% de la varianza a lo largo del PC1 y los altos índices de correlación entre réplicas respaldan la complejidad y calidad de los resultados. La concordancia general con los datos reportados en Expression Atlas valida la metodología implementada con DESeq2. Este trabajo confirma los mecanismos transcripcionales fundamentales de la especificación del endodermo y también establece un pipeline confiable para el análisis reproducible de datos de secuenciación en el contexto de la diferenciación celular.

Referencias

D'Amour, K. A., Agulnick, A. D., Eliazar, S., Kelly, O. G., Kroon, E., & Baetge, E. E. (2005). Efficient differentiation of human embryonic stem cells to definitive endoderm. *Nature Biotechnology*, *23*(12), 1534–1541. <https://doi.org/10.1038/nbt1163>

Madrigal, P., Gòdia, M., Ruiz-Herguido, C., Guillaumet-Adkins, A., Pegenaute, F., Sandoval, J., & Heyn, H. (2023). Epigenetic and transcriptional regulations prime cell fate before division during human pluripotent stem cell differentiation. *Nature Communications*, *14*(1), 1011. <https://doi.org/10.1038/s41467-023-36116-9>

Rojas, A., De Val, S., Heidt, A. B., Xu, S.-M., Bristow, J., & Black, B. L. (2010). Gata4 expression in lateral mesoderm is downstream of BMP4 and is activated directly by Forkhead and GATA transcription factors through a distal enhancer. *Developmental Biology*, *340*(2), 255–266. <https://doi.org/10.1016/j.ydbio.2010.01.038>

Diekmann, U., Wolling, H., Dettmer, R., Striebel, J., Hillebrandt, K., Nevermann, S., Seiffert, N., Klose, K., Kempf, H., & Zweigerdt, R. (2019). Chemically defined and xenogeneic-free differentiation of human pluripotent stem cells into definitive endoderm in 3D culture. *Scientific Reports*, *9*(1), 996. <https://doi.org/10.1038/s41598-018-37650-z>

Base de datos E-MTAB-9194:
Expression Atlas. (s. f.). *Experiment E-MTAB-9194: RNA-seq of definitive endoderm differentiation in human G1-synchronized stem cells*. European Molecular Biology Laboratory-European Bioinformatics Institute (EMBL-EBI). Recuperado 18 de noviembre de 2025, de <https://www.ebi.ac.uk/gxa/experiments/E-MTAB-9194>