

**Análisis de Expresión Diferencial del Transcriptoma durante la
Transición de Pluripotencia a Endodermo Definitivo en Células Madre
Humanas: Una Reproducción Computacional del Experimento E-MTAB-
9194**

Laura del Sol González

Universidad EIA

Trabajo Final Bioinformática

2025

Descripción del estudio original

El estudio "Epigenetic and transcriptional regulations prime cell fate before division during human pluripotent stem cell differentiation" investiga los cambios dinámicos en el transcriptoma y el epigenoma durante la diferenciación de células madre embrionarias humanas (hESC) hacia endodermo definitivo (Madrigal et al., 2023). Para ello, los autores establecieron un sistema de diferenciación sincronizada utilizando el reportero FUCCI (Fluorescent Ubiquitination-based Cell Cycle Indicator), que permite visualizar y aislar poblaciones celulares en fases específicas del ciclo celular en base a la fluorescencia de proteínas ligadas a ubiquitina. Gracias a este sistema, los autores pudieron sincronizar las células en la fase G1 temprana (0 horas), estableciendo un punto de partida homogéneo y bien definido para inducir la diferenciación de manera coordinada.

En el diseño experimental, las células en la fase G1 temprana representan el estado de pluripotencia de las hESC no diferenciadas. Por el contrario, el tiempo de 72 horas representa una etapa avanzada en la que las células han activado los programas transcripcionales de diferenciación y se han diferenciado al linaje de endodermo definitivo, como lo demuestra la en el artículo la expresión de marcadores específicos clave (Madrigal et al., 2023). Esta ventana de tiempo es una transición celular fundamental, que es la pérdida del estado pluripotente y la adquisición de una nueva identidad celular especializada (Madrigal et al., 2023). En el estudio original se realizó un análisis de la expresión génica diferencial a lo largo de una serie temporal completa que moprendia de las 0 a las 72 horas pasando por intervalos de tiempo de 12, 24, 36, 48 y 50 horas para determinar mecanismos dependientes del ciclo celular en los diferentes periodos de tiempo donde la célula entraba en 2 fases del ciclo celular. Sin embargo, este proyecto se centra en el contraste más fundamental entre el estado inicial y el estado final diferenciado, pues el replicar las condiciones que se planteaban en el estudio para ver en qué fase del ciclo se encontraba la célula ya no era parte del análisis diferencial, además que se desarrollaban en tiempos distintos a las 72 horas. A pasar de esto la comparación directa entre estos dos estados es biológicamente muy importante y adecuada para un análisis de expresión diferencial menos completo. Se espera que esta transición esté impulsada por amplios cambios transcriptómicos, incluida la supresión de genes asociados

con la pluripotencia y la activación de una red génica que impulsa la especificación del endodermo.

Entre los reguladores transcripcionales centrales cuya sobreexpresión se anticipa en las 72 horas según el estudio se encuentran EOMES, un factor crítico para la inducción del mesendodermo; SOX17, un marcador definitorio del endodermo definitivo; GATA4, un factor de transcripción esencial para el desarrollo endodérmico que actúa en una jerarquía con FOXA2 (Rojas et al., 2010); y LZTS1, un gen identificado en el estudio original cuya expresión se incrementa tempranamente durante la diferenciación (Madrigal et al., 2023).

Diseño experimental

El diseño experimental del estudio original comprendió una serie temporal con siete puntos de muestreo (0, 12, 24, 36, 48, 60 y 72 horas) para capturar la dinámica de la diferenciación. Para el presente análisis, se definió un contraste específico entre dos condiciones biológicas discretas: células madre embrionarias humanas (hESC) en estado de pluripotencia (0 h) versus células diferenciadas a endodermo definitivo (72 h).

La variable biológica central es el estado de diferenciación celular, representado por dos niveles: el estado inicial pluripotente (0 h) que actúa como control, y el estado final de endodermo definitivo (72 h) que constituye el tratamiento o condición experimental.

Cada condición cuenta con tres réplicas biológicas independientes. Estas réplicas consisten en cultivos celulares preparados de forma separada y sometidos al protocolo de diferenciación de manera independiente, lo que permite capturar la variabilidad biológica inherente al proceso y garantiza la robustez estadística del análisis.

Análisis metodológico

Primero se extrajeron conteos crudos y metadatos desde Expression Atlas, seleccionando sólo las muestras de interés (réplicas 0 h y 72 h) como se muestra en el README. Se formó una matriz de conteos con genes como filas y muestras como columnas, y se creó el objeto DESeq2 con diseño de tiempo como factor. Se filtraron genes de muy baja expresión (suma de conteos ≤ 10) antes del análisis para reducir ruido.

Tras ejecutar DESeq2 (estimación de tamaños de librería, dispersión y test de Wald) se obtuvieron valores de $\log_2FC$ y p-valores ajustados. Como umbrales de significancia se usaron $FDR (padj) < 0.01$ y $\log_2FC \geq \log_2(1.5)$ siguiendo el criterio del estudio original. El uso de FDR controla la tasa de falsos positivos en pruebas. Se identificaron aproximadamente 9600 genes diferencialmente expresados bajo estos criterios. Entre los más significativos destacan los marcadores de diferenciación (**EOMES**, **SOX17**, **GATA4**, **LZTS1**).

Durante el análisis se realizaron controles de calidad: se aplicó la transformación VST para homogeneizar varianza y se generó un PCA para verificar la separación nítida entre condiciones. También se calculó la matriz de correlación de Spearman entre réplicas, mostrando alta concordancia y clustering adecuado, esto también se hizo siguiendo el criterio del estudio original.

Resultados




Figura 1. Boxplots de genes marcadores. Muestra los conteos brutos de **EOMES**, **SOX17**, **LZTS1**, **GATA4** en 0 h vs 72 h. Se observa que en el tiempo 0 los niveles son bajos/ausentes y en el tiempo 72 los niveles aumentan drásticamente, consistente con la activación de la ruta endodérmica.




Figura 2. MA-plot. El MA-plot relaciona la expresión media de cada gen con su $\log_2FC$. Se aprecia una nube dispersa alrededor de cero, con los genes significativamente diferenciados resaltados. La simetría sugiere un balance entre genes sobre- y sub-expresados, y muestra que los cambios más extremos corresponden a genes de baja o media expresión. Este gráfico permite detectar sesgos (que no hay) y confirma la proporción de genes con grandes cambios.




Figura 3. PCA: Separación entre 0h y 72. El diagrama de componentes principales muestra dos grupos bien diferenciados por tiempo (0 h en rojo, 72 h en azul). El primer componente (PC1) captura casi toda la variación biológica entre estados celulares (el código nos dice que PC1 representa el 100% de la varianza mientras que el PC2 representa el 0%), indicando que el cambio celular es la fuente principal de variabilidad. Esto refuerza la calidad del proyecto y la consistencia de los replicados diferenciados.

(D'Amour et al., 2005). Los datos confirman este patrón, mostrando un aumento significativo de SOX17 y FOXA2 junto con una disminución marcada de POU5F1 y SOX2 tras 72 horas de diferenciación, validando la transición al linaje endodérmico.

Entre los genes diferenciales clave, destacan:

- **EOMES (Eomesodermina):** es un factor maestro temprano de endodermogénesis. Marca el inicio del engrosamiento endodérmico y colabora con SMAD2/3 para activar la red genética endodérmica (Diekmann, U et al. , 2019). Estudios muestran que EOMES es necesario para la formación de endodermo (su pérdida impide la expresión de SOX17, FOXA2, GATA4) y que su expresión se induce tras los 24–36 h de diferenciación. En el análisis realizado aparece altamente sobreexpresado en 72 h.
- **SOX17 y GATA4:** ambos son factores de transcripción esenciales del endodermo definitivo. SOX17 regula genes de endodermo y es crítico para la formación de los órganos derivados (intestino, páncreas) (Diekmann, U et al. , 2019) . GATA4 (junto con GATA6) activa genes endodérmicos tempranos; su inducción coopera con EOMES/SMAD2/3 para consolidar la identidad endodérmica (introduciendo un circuito autorregulador) (Diekmann, U et al. , 2019). La fuerte inducción observada de SOX17 y GATA4 en 72 h refleja esta función.
- **LZTS1 (leucine zipper, putative tumor suppressor 1):** Aunque originalmente asociado a regulación de ciclo celular, estudios recientes (Madrigal et al., 2023) identifican a LZTS1 como regulador potencial del endodermo. Su expresión aumenta rápidamente después de 36 horas, sincronizada con la activación de SOX17/GATA factores. También se observó que la sobreexpresión de LZTS1 en hESCs potencia la expresión de EOMES, SOX17 y GATA4 al día 3 (72 h) (Diekmann, U et al. , 2019), sugiriendo un papel positivo en la transición de destino. El hallazgo de LZTS1 en los resultado dio que estaba muy inducido ($\log_2FC=4.68$) .

En conjunto, el panorama transcriptómico global revela un cambio masivo, pues miles de genes alteran su expresión, reflejando la migración de redes de pluripotencia a redes de destino celular. Estudios confirman que la mayoría de la variación ocurre durante la fase G1 temprana y antes/después de las primeras divisiones celulares en este sistema, lo cual es

coherente con nuestra observación de variabilidad concentrada en la diferenciación inicial. La lista de genes diferenciados por el estudio se sabe que incluyen funciones metabólicas, de señalización celular y cambio en la cromatina mostrando la complejidad del proceso tal como lo documentan Madrigal et al. (2023). Lo que significa que la evidencia que el cambio de estado está dirigido por la transcripción de factores específicos (EOMES, SOX17, GATA4, LZTS1) y por la represión de la red pluripotente.

Comparación con Expression Atlas

Este análisis reproduce las tendencias reportadas por Expression Atlas. En particular, **EOMES, SOX17, GATA4 y LZTS1** aparecen sobre expresados en 72 h vs 0 h y concuerda en dirección (todos hacia arriba) y magnitud creciente (variaciones de varios órdenes de magnitud). Por ejemplo, el incremento $\log_2FC$ de EOMES (5.79) y SOX17 (5.46) en los datos es consistente con la marcada inducción en endodermo de estos genes . Además, el número total de genes diferenciados que se encontraron (aproximadamente 9600 con los filtros propuestos) es aproximadamente el mismo orden de magnitud que el reportado en Expresión atlas (aproximadamente 7000), las diferencias numéricas pueden explicarse por usar umbrales distintos o filtrados previos de conteos no explicados en el artículo, y por métodos de normalización diferentes. A pesar de esto, la superposición de genes relevantes es alta.

En cuanto a validación cruzada, se encontró que los hallazgos biológicamente importantes como la activación de LZTS1 y de los marcadores endodérmicos aparecen de forma reproducible. Por ejemplo, ambos conjuntos de datos señalan que LZTS1 surge como regulador ligado al endodermo. Finalmente, al ver los patrones de expresión se encuentran que más o menos la mitad son ascendentes y el resto descendentes, algo que también se ve en el expresión atlas.





Gene_ID	chromosome	start_position	end_position	baseMean	log2FoldChange	rCSE	stat	pvalue	padj	Gene_Name
ENSG000001chr11		3392961	3379292	51.152.153.643.713	-0.58772883	0.036462847	-161.203.217.266.414	1.84E-45	1.43E-43	ZNF195
ENSG000001chr1		48930180	48930180	358.525.411.261.624	-0.587445031	0.04227868	-138.965.029.710.114	6.65E-30	4.30E-29	SLC93A1
ENSG000001chr6		16509799	16729796	69.617.551.518.714	-0.58732155	0.02994389	-195.810.447.543.244	2.24E-72	2.35E-70	CTP2
ENSG000001chr12		125459686	125459686	127.238.247.908.217.249	-0.587304709	0.04227868	-138.965.029.710.114	6.65E-30	4.30E-29	SLC93A1
ENSG000001chr16		64099711	64172958	175.219.208.592.352	-0.586918708	0.07272825	-125.126.090.415.1254	1.19E-47	1.87E-46	ITP18
ENSG000001chrX		49187987	49200283	221.004.652.664.199	-0.586769547	0.134803457	-420.675.589.567.731	2.59E-09	6.09E-09	SPY
ENSG000001chr4		39287456	39356619	907.360.278.628.612	-0.586594218	0.029614024	-198.079.875.711.159	2.54E-74	2.72E-72	RFCL1
ENSG000001chr10		2484614	24952606	102.999.866.557.638	-0.5863575	0.07236825	-150.050.182.231.511	5.24E-92	1.94E-91	PRFTD1
ENSG000001chr21		43639960	43690676	111.925.252.216.892	-0.586466066	0.027842063	-210.640.146.366.158	1.64E-64	2.04E-63	RRP1B
ENSG000001chr1		10398162	10398167	349.712.196.306.305	-0.586434963	0.04227868	-138.965.029.710.114	6.65E-30	4.30E-29	SLC93A1
ENSG000001chrX		13559262	13558254	174.152.200.554.705	-0.586421057	0.053693599	-195.810.447.543.244	2.24E-72	2.35E-70	CTP2
ENSG000001chr18		52482889	52488634	73.239.625.131.75	-0.586193766	0.120399974	-486.872.002.527.151	1.12E-08	2.88E-08	PDHSL
ENSG000001chr12		6867119	6870948	907.219.651.997.735	-0.58607453	0.020215574	-291.206.275.834.889	1.97E-72	4.16E-71	TP11
ENSG000001chr10		12247160	12250932	383.534.785.789.338	-0.58676972	0.038638352	-151.579.178.320.747	6.72E-38	8.41E-38	ZCCHC8
ENSG000001chr11		113056710	11309682	522.517.712.120.933	-0.585570897	0.087160923	-617.828.080.863.196	1.84E-04	5.88E-03	ATX1
ENSG000001chr1		171779780	171779780	171.719.276.276.278	-0.585531263	0.086835176	-617.828.080.863.196	1.84E-04	5.88E-03	ATX1
ENSG000001chr2		6667961	6850563	412.519.010.040.559	-0.585158582	0.104749090	-550.090.919.919.919	3.22E-06	6.50E-06	HDGAP2
ENSG000001chr20		79737346	8019163	302.773.255.156.346	0.58575734	0.047413241	123.642.882.488.523	5.11E-51	2.84E-50	TMXN1
ENSG000001chr1		9846269	9910368	471.568.327.232.792	0.585398854	0.033908342	172.488.938.682.745	1.14E-52	9.95E-52	CNNB1P1
ENSG000001chr8		89544523	89902429	138.648.301.543.914	0.58597704	0.060874897	962.590.422.899.823	6.62E-08	2.66E-07	CTD
ENSG000001chr17		32044337	32044334	196.456.836.738.138	0.58630029	0.143494692	408.586.744.935.689	4.99E-01	0.000102	HSGP11
ENSG000001chr1		18504237	18509026	266.215.525.406.185	0.58631821	0.046887656	127.778.980.527.813	2.14E-52	2.72E-52	SNRNP
ENSG000001chr15		89608789	89663098	269.323.242.890.796	0.586460976	0.042015555	159.600.598.2422	2.73E-30	1.77E-29	SPY
ENSG000001chr2		232857270	232878708	307.669.391.269.165	0.586811783	0.139898762	302.497.422.455.002	0.02487	0.00491	SNORC
ENSG000001chr12		10593836	1059829	323.056.671.255.346	0.58697744	0.112913716	51.984.600.6429	2.01E-06	0.53E-07	KLRAP1
ENSG000001chr6		8435542	894133	100.463.012.796.777	0.588537399	0.299398329	283.832.391.921.08	0.458E-03	0.0966E-02	UCP
ENSG000001chr9		1971111	1971111	16.162.162.672.5165	0.586989708	0.195195833	117.498.345.320.491	0.235E-57	0.0003E-4	SLC12A2
ENSG000001chr1		81017983	81017983	26.854.447.872.882	0.580447562	0.194471562	60.666.666.666.666	0.0001E-02	0.0001E-02	BNP2P2
ENSG000001chr15		57191500	5722084	215.586.064.121.66	0.589301013	0.050159593	116.648.621.029	7.08E-18	1.77E-17	CTP2

Imagen 2. En el archivo `deseq_filtrado_FC1.5_padj.csv` se organizó el `logfoldchange` de menor a mayor y en el dato 5004 se observa el cambio de down a up regulated.

Conclusión

Este proyecto demuestra la viabilidad de reproducir exitosamente un análisis de expresión diferencial de RNA-seq a partir de datos públicos, validando los hallazgos centrales del estudio original de Madrigal et al. (2023). El análisis confirmó el patrón transcripcional característico de la diferenciación a endodermo definitivo, con la represión de genes de pluripotencia y la activación significativa de reguladores endodérmicos clave. Los controles de calidad realizados, incluyendo el PCA que mostró una separación del 100% de la varianza a lo largo del PC1 y los altos índices de correlación entre réplicas respaldan la complejidad y calidad de los resultados. La concordancia general con los datos reportados en Expression Atlas valida la metodología implementada con DESeq2. Este trabajo confirma los mecanismos transcriptómicos fundamentales de la especificación del endodermo y también establece un pipeline confiable para el análisis reproducible de datos de secuenciación en el contexto de la diferenciación celular.

Referencias

D'Amour, K. A., Agulnick, A. D., Eliazer, S., Kelly, O. G., Kroon, E., & Baetge, E. E. (2005). Efficient differentiation of human embryonic stem cells to definitive endoderm. *Nature Biotechnology*, *23*(12), 1534–1541. <https://doi.org/10.1038/nbt1163>

Madrigal, P., Gòdia, M., Ruiz-Herguido, C., Guillaumet-Adkins, A., Pegenaute, F., Sandoval, J., & Heyn, H. (2023). Epigenetic and transcriptional regulations prime cell fate before division during human pluripotent stem cell differentiation. *Nature Communications*, *14*(1), 1011. <https://doi.org/10.1038/s41467-023-36116-9>

Rojas, A., De Val, S., Heidt, A. B., Xu, S.-M., Bristow, J., & Black, B. L. (2010). Gata4 expression in lateral mesoderm is downstream of BMP4 and is activated directly by Forkhead and GATA transcription factors through a distal enhancer. *Developmental Biology*, *340*(2), 255–266. <https://doi.org/10.1016/j.ydbio.2010.01.038>

Diekmann, U., Wolling, H., Dettmer, R., Striebel, J., Hillebrandt, K., Nevermann, S., Seiffert, N., Klose, K., Kempf, H., & Zweigerdt, R. (2019). Chemically defined and xenogeneic-free differentiation of human pluripotent stem cells into definitive endoderm in 3D culture. *Scientific Reports*, *9*(1), 996. <https://doi.org/10.1038/s41598-018-37650-z>

Base de datos E-MTAB-9194:
Expression Atlas. (s. f.). *Experiment E-MTAB-9194: RNA-seq of definitive endoderm differentiation in human G1-synchronized stem cells*. European Molecular Biology Laboratory-European Bioinformatics Institute (EMBL-EBI). Recuperado 18 de noviembre de 2025, de <https://www.ebi.ac.uk/gxa/experiments/E-MTAB-9194>